

# 基于生成对抗网络和深度神经网络的武器系统效能评估

李 健 刘海滨 胡 笛

(中国航天系统科学与工程研究院 北京 100048)

**摘 要** 武器系统的效能评估受很多因素的影响,神经网络是现代武器系统效能评估的重要方法,但受样本量的限制,很难达到预期的训练效果。针对这一问题,选取少批量真实数据训练生成对抗网络,待网络达到纳什均衡后,利用生成网络产生同分布的伪数据。将伪数据与真实数据结合形成扩增样本,使用扩增样本训练深度神经网络用以评估。同时,生成对抗网络中的判别网络也能为专家评估提供一定的参考。

**关键词** 武器系统 效能评估 生成对抗网络 扩增样本 深度神经网络

中图分类号 TP18 文献标志码 A DOI:10.3969/j.issn.1000-386x.2020.02.039

## WEAPON SYSTEM EFFECTIVENESS EVALUATION BASED ON GENERATIVE ADVERSARIAL NETWORK AND BP NEURAL NETWORK

Li Jian Liu Haibing Hu Di

(China Aerospace Academy of Systems Science and Engineering, Beijing 100048, China)

**Abstract** Effectiveness evaluation of weapon system is affected by many factors. Neural network is an important method for evaluating the effectiveness evaluation of modern weapon system. However, due to the limited by the sample size, it is difficult to achieve the desired training effect. In order to solve this problem, a small batch of real data was selected to train the generative adversarial network. When the network reached Nash equilibrium, the generative network was used to generate pseudo data with the same distribution. Then, the pseudo data was combined with real data to form an amplified sample. The amplified sample was used to train the depth neural network for evaluation. In addition, the discriminative network in the generative adversarial network can also provide a certain reference for expert evaluation.

**Keywords** Weapon system Effectiveness evaluation Generative adversarial network Amplified sample Deep neural network

## 0 引 言

武器系统的效能通常指的是在特定环境下武器完成任务的能力,是规划、研发武器系统的基本依据,也是评价武器系统极其重要的指标,是军事运筹研究的出发点和归宿<sup>[1]</sup>。

由于武器系统的复杂性,导致其效能的评估变得尤其困难。武器系统的评估,必须要综合考虑影响其效能的所有重要指标。现阶段评价武器系统的方法主要有神经网络<sup>[2-3]</sup>、支持向量机<sup>[4]</sup>和模糊综合评估<sup>[5]</sup>等方法,每种方法都各有优劣<sup>[6]</sup>。

基于神经网络的评估方法简单易行,但最终效果

对于训练集的大小有一定的依赖性。若训练集太小,容易造成欠拟合,模型找到的规律不能很好地表现数据特征,进而不能准确地拟合预测结果。

基于支持向量机的评估方法对于小样本数据有比较好的预测效果,但支持向量机对缺失数据敏感,同时对于非线性问题核函数的选择没有通用的解决方案。

基于模糊综合评估法的模型,能够将影响因素全部纳入考量范围,准确率较高,但其中的隶属度函数和权值的选择目前还存在不确定,需要人工进行选取。

本文主要是针对神经网络评估的劣势问题,提出了“生成对抗网络+深度神经网络”的解决方案。探索研究生成对抗网络在样本扩增方面的应用,结合深度神经网络建立评估模型,并对其效果和性能进行了

对比分析。

1 系统评估主要算法

1.1 生成对抗网络

生成对抗网络 (GAN, Generative Adversarial Nets) 是一种深度学习模型,最早由 Goodfellow 等<sup>[7]</sup>于 2014 年 10 月提出。GAN 的优化过程是一个极小极大博弈问题,其优化目标是达到纳什均衡<sup>[8]</sup>。

生成对抗网络如图 1 所示,包括两部分,生成模型  $G$  和判别模型  $D$ 。生成模型  $G$  用于获取数据的分布,判别模型  $D$  用于估算数据来自于训练样本还是生成模型  $G$  的概率。 $G$  的训练是为了使得  $D$  最大化犯错误的可能性。该模型类似于一个双人博弈游戏,在  $G$  和  $D$  的函数解空间中存在着唯一解。伴随着  $G$  得到训练数据的分布, $D$  输出的概率逐渐趋于 1/2。当  $G$  和  $D$  定义为多层感知器的情况下,整个系统可以通过反向传播进行训练。在训练和产生样本的过程中,不需要任何的马尔可夫链或者近似推理网络。




图 1 GAN 算法的基本结构

生成模型  $G$ : 一个生成网络,通过接收噪声  $z$ ,产生伪数据  $G(z)$ ;

判别模型  $D$ : 一个判别网络,通过接收输入样本数据  $x$ ,输出数据是真数据还是  $G(z)$  的概率  $D(x)$ 。

对于判别模型  $D$ ,其目的是区分数据的真假,即来自于原样本数据  $x$  的  $D(x)$  的输出越接近于 1 越好,而对于  $D(G(z))$  越接近于 0 越好。对于生成模型  $G$ ,其目的是使该模型产生的伪数据  $G(z)$  尽可能地骗过判别模型  $D$ ,即  $D(G(z))$  越大越好<sup>[9]</sup>。因此,GAN 中  $D$  与  $G$  的训练便成为使用函数  $V(G,D)$  的二者博弈极小极大值问题:

$$\min_G \max_D V(D,G) =$$

$$E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (1)$$

对应生成模型  $G$  和判别模型  $D$  的代价函数为:

$$\min_G V(D,G) = -E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2)$$

$$\max_D V(D,G) = -E_{x \sim p_{data}(x)} [\log D(x)] - E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (3)$$

1.2 深度神经网络

深度神经网络<sup>[10-11]</sup>如图 2 所示,其内部结构可以分为三层:输入层、多层隐藏层和输出层。深度神经网络

是一种有效的多层神经网络学习方法,其主要特点是信号前向传递,而误差后向传播,通过不断调节网络权重值,使得网络的最终输出与期望输出尽可能接近,以达到训练的目的。




图 2 深度神经网络的基本结构

假设有  $m$  个训练样本,其中  $t_k$  为对于输入  $x_k$  的期望输出。其一般代价函数  $E_p$  为:

$$E_p = \sum_{k=1}^m \frac{1}{2} (y_k - t_k)^2 \quad (4)$$

利用得到的误差值进行逆向传播,利用求导等方式得到神经元权值  $\omega$ 、偏执量  $b$  的修正:

$$\Delta \omega(i,j) = -\eta \frac{\partial E(\omega,b)}{\partial \omega(i,j)} \quad (5)$$

$$\Delta b(i,j) = -\eta \frac{\partial E(\omega,b)}{\partial b(i,j)} \quad (6)$$

式中: $\omega$  为权值, $\eta$  为学习率, $\frac{\partial E}{\partial \omega}$  为误差对权值的导数, $\frac{\partial E}{\partial b}$  为误差对偏执量的导数。

$$\frac{\partial E}{\partial \omega} = \frac{1}{n} \sum_x (\sigma(z) - y) x_j \quad (7)$$

$$\frac{\partial E}{\partial b} = \frac{1}{n} \sum_x (\sigma(z) - y) \quad (8)$$

可以看出,神经元权值和偏执量的变化取决于误差,与激活函数无关。

1.3 支持向量回归

支持向量回归 (Support Vector Regression, SVR) 是 Vapnik 等在 1996 年提出的应用在数据拟合问题的向量机算法。与传统的 SVM (Support Vector Machine) 相比,SVR 的目的也是寻找最优超平面,但是 SVR 能找到更准确预测数据分布的平面<sup>[12]</sup>。目前,SVR 算法在数据的拟合、预测等方面有着非常良好的效果。

SVR 模型表示为:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*) \quad (9)$$

$$\begin{aligned} y_i - w \cdot \phi(x_i) - b &\leq \varepsilon + \xi_i \\ w \cdot \phi(x_i) + b - y_i &\leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* &\geq 0, i = 1, 2, \dots, l \end{aligned} \quad (10)$$

经过拉格朗日函数及其求偏导数一系列变化之后可得到最终需要优化的目标  $W$  为:

$$\begin{aligned} W(\alpha, \alpha^*) = & -\frac{1}{2} \sum_{i=1}^n (\alpha_i - \alpha_i^*)(\alpha_i - \alpha_i^*) \cdot (\Phi(x_i) \cdot \Phi(x_j)) + \\ & \sum_{i=1}^n (\alpha_i - \alpha_i^*) y_i - \sum_{i=1}^n (\alpha_i + \alpha_i^*) \varepsilon \end{aligned} \quad (11)$$

式中:  $\xi_i, \xi_i^*$  为松弛因子,  $C$  为惩罚系数,  $\varepsilon$  为误差,  $w, b$  为待确定参数, 函数  $\Phi$  为未知函数,  $y_i$  为标签,  $\alpha_i, \alpha_i^* \geq 0$ , 为拉格朗日乘数,  $K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$  可以表示为核函数。

由此可知, SVR 的性能主要取决于参数  $C, \varepsilon$ 、核函数类型以及核参数。常用的核函数包括: 线性核、多项式核、径向基核函数等。

## 2 模型构建及评价指标

### 2.1 模型构建

本文运用 GAN 算法进行数据生成, 同时利用深度神经网络进行预测, 实现诸多影响因素与最终结果之间的映射关系。其详细过程如图 3 所示。

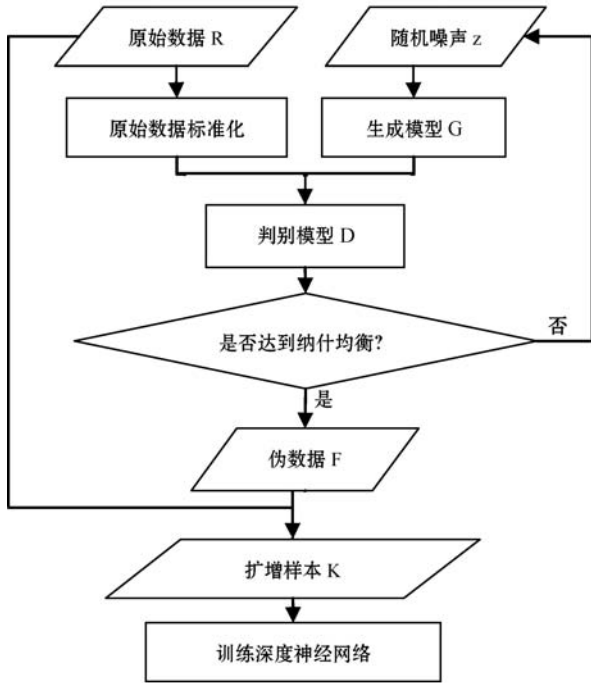


图 3 模型构建流程图

由于影响电子对抗的因素种类较多, 且不同因素之间的量纲不同, 不具有可比性。因此, 在实验过程中, 首先对原始数据进行标准化处理, 将其统一转化到  $[-1, 1]$  区间。每组影响因素之间的转化公式为:

$$x_i = \frac{x_i - \min(x)}{\max(x) - \min(x)} \times 2 - 1 \quad (12)$$

将标准化后的数据进行生成对抗网络训练, 其中, 主要是生成模型  $G$  和判别模型  $D$  的博弈。使用随机噪声和真实样本数据训练生成网络和判别网络, 使得两者达到纳什均衡, 最终获得功能强大的判别网络和可模拟原数据的生成网络。

生成模型  $G$  是一个生成网络, 通过接收随机高斯噪声  $z$ , 产生伪数据  $G(z)$ 。假设已知训练样本的分布  $p(x)$ , 那么就可以在分布中随机抽样得到新样本。生成模型就是在不断循环和训练中得到噪声  $z$  和训练样本  $x$  之间的关系。在实验中, 随机噪声服从均值为 0, 标准差为 1 的高斯分布  $N(0, 1)$ 。

判别模型  $D$  是一个判别网络, 通过接收输入  $x$ , 输出数据是真数据还是  $G(z)$  的概率  $D(x)$ 。对于判别模型  $D$ , 其目的是区分数据的真假, 即来自于原样本数据  $x$  的  $D(x)$  的输出越接近于 1 越好, 而  $D(G(z))$  越接近于 0 越好; 对于生成模型  $G$ , 其目的是使该模型产生的伪数据  $G(z)$  尽可能地骗过判别模型  $D$ , 即  $D(G(z))$  越大越好。通过生成模型  $G$  和判别模型  $D$  的相互博弈和训练, 使得  $G$  和  $D$  的性能在迭代过程中不断提升, 最终达到纳什均衡状态。

GAN 模型采用随机梯度上升更新判别模型, 同时采用随机梯度下降更新生成模型, 设置最大迭代次数  $T = 500$ , 判别模型的训练步数  $k$  是一个超参数, 实验中  $k = \text{Round}(N / \text{batch})$ ,  $\text{Round}(\cdot)$  表示取整函数,  $N$  表示样本量,  $\text{batch}$  表示每次取出样本的数量。

从分布  $p_z(z)$ 、 $p_{\text{data}}(x)$  的  $m$  个样本  $\{z_1, z_2, \dots, z_m\}$ 、 $\{x_1, x_2, \dots, x_m\}$  中分别选取  $\text{batch}$  个样本, 利用式 (3) 计算其代价函数, 通过随机梯度上升更新判别模型:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m [\log D(x_i) + \log(1 - D(G(z_i)))] \quad (13)$$

待  $k$  次训练更新判别模型之后, 从分布  $p_z(z)$  的  $m$  个样本  $\{z_1, z_2, \dots, z_m\}$  中选取  $\text{batch}$  个样本, 利用式 (2) 计算其代价函数, 通过随机梯度下降更新生成模型:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z_i))) \quad (14)$$

假设有真实数据  $\text{data}$ , 可以看作一组向量,  $p_{\text{data}}(x)$  为真实数据对应分布。在整个训练过程中,  $p_z(z)$  逐渐地收敛于  $p_{\text{data}}(x)$ 。对应有如下理论:

**定理 1** 固定  $G$ , 得到最优的判别模型  $D$ :

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_z(x)} \quad (15)$$

证明: 固定  $G$ , 原最优函数转化为求  $\max_D V(D, G)$ 。将原公式中的数学期望展开为积分形式。

$$V(G,D) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] =$$
$$\int_x p_{data}(x) \log D(x) dx + \int_z p_z(z) \log(1 - D(G(z))) dz =$$
$$\int_x (p_{data}(x) \log D(x) + p_z(x) \log(1 - D(x))) dx \quad (16)$$

求积分的最大值可以转化为求被积函数的最大值。上式中不涉及判别模型  $D$  的项都可以看作常数项。因此,被积函数可以表示为  $f(D) = a \log D + b \log(1 - D)$ 。当被积函数导数为 0 时, $D$  可以取到最大值。

$$\frac{df(D)}{dD} = a \times \frac{1}{D} + b \times \frac{1}{1 - D} \times (-1) = 0 \quad (17)$$

计算可得:

$$D^* = \frac{a}{a + b} = \frac{p_{data}(x)}{p_{data}(x) + p_z(x)} \quad (18)$$

**定理 2** 如果  $G$  和  $D$  有足够的性能,对于上述定理 1 中的每一步,给定  $G$ ,判别模型能够达到最优,并且通过更新  $p_z(x)$  来提高判别准则:

$$E_{x \sim p_{data}(x)} [\log D_G^*(x)] + E_{z \sim p_z(x)} [\log(1 - D_G^*(x))] \quad (19)$$

要使得上式值达到最优,则  $D^*(x) = 1/2$ ,即  $p_z(x) = p_{data}(x)$ 。

证明:将定理 1 中的结果代入目标函数中:  
 $C(G) = V(G, D^*) =$

$$E_{x \sim p_{data}} \left[ \log \frac{p_{data}(x)}{p_{data}(x) + p_z(x)} \right] + E_{x \sim p_z} \left[ \log \left( 1 - \frac{p_{data}(x)}{p_{data}(x) + p_z(x)} \right) \right] =$$
$$\int_x p_{data}(x) \log \frac{p_{data}(x)}{p_{data}(x) + p_z(x)} dx +$$
$$\int_x p_z(x) \log \left( 1 - \frac{p_{data}(x)}{p_{data}(x) + p_z(x)} \right) dx \quad (20)$$

假定当前达到最优平衡状态,即  $p_z(x) = p_{data}(x)$ ,此时  $D^*(x) = \frac{1}{2}$ ,代入式(20),得到对应结果为  $-\log 4$ 。使用 KL 散度来衡量任意时刻  $C(G)$  离平衡状态的差距:

$$C(G) = -\log 4 + KL \left( p_{data} \parallel \frac{p_{data} + p_z}{2} \right) + KL \left( p_z \parallel \frac{p_{data} + p_z}{2} \right) \quad (21)$$

从 JS 距离的定义可知,当且仅当  $KL(a \parallel b)$  中的  $a = b$  时,等号成立。所以当  $p_z(x) = p_{data}(x)$  时:

$$C(G) = -\log 4 + 2JSD(p_{data} \parallel p_g) \geq -\log 4 \quad (22)$$

当且仅当  $D^*(x) = 1/2$ ,即  $p_z(x) = p_{data}(x)$  时,该不等式取到等号, $C(G)$  取到最小值。

由定理 1 和定理 2 可得,整个模型达到纳什均衡后,生成模型已经得到原数据分布的良好的估计分布,即  $p_z(z) = p_{data}(x)$ 。

待对抗网络训练结束后,使用训练后的生成模型生成一定量的伪数据  $F$ ,与原始样本数据  $R$  组成扩增样本  $K$ 。较原始数据相比,扩增样本分布与其基本一

致,但数据量有明显提升。

使用扩增样本  $K$  训练基于 BP 神经网络的深度网络,深度网络共 11 个输入节点,中间多层隐藏层,一个输出节点。通过误差的反向传播理论,利用式(4) - 式(8)逐层反向传播,修正偏执量和神经元权值。最终得到一个完整的生成对抗网络和深度神经网络的模型。

2.2 指标体系

本文以电子对抗的效能评估为例进行说明。由于影响电子对抗的因素太多,这里选取干扰强度、干扰时间、检索速率、干扰频率、距离检索范围、距离追踪范围、距离追踪精度、角度跟踪精度、速度追踪范围和速度追踪精度等作为影响因子<sup>[13-15]</sup>。

2.3 模型评价指标

本文采用均方根误差(Root Mean Square Error, RMSE)作为模型的评价指标。RMSE 是预测值与实际值之差的平方和与数据总量比值的平方根。与标准差对比,均方根误差用来衡量预测值和实际值之间的偏差,标准差则衡量一组数据自身的离散程度。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (d_i - p_i)^2} \quad (23)$$

3 实验设计及结果分析

实验使用 226 个测试数据作为原始样本数据,利用生成模型生成伪数据的扩增样本为 1 800 个。归一化后的数据样本如表 1 所示。

表 1 归一化之后的数据样本

score	v1	v2	v3	...	v9	v10
0.690 0	0.297 9	0.968 7	0.282 6	...	0.009 2	0.864 7
0.576 8	0.223 4	0.785 4	0.130 4	...	0.223 9	0.173 9
0.769 0	0.287 2	0.904 6	0.043 5	...	0.211 7	0.603 9
0.916 4	0.063 8	0.928 5	0.087 0	...	0.098 2	0.739 1
0.684 4	0.361 7	0.967 2	0.065 2	...	0.417 2	0.855 1
0.737 1	0.234 0	0.959 8	0.152 2	...	0.061 3	0.840 6
⋮	⋮	⋮	⋮		⋮	⋮
0.490 2	0.627 7	0.928 5	0.065 2	...	0.147 2	0.739 1
0.630 2	0.521 3	0.928 5	0.043 5	...	0.564 4	0.729 5
0.864 9	0.255 3	0.934 4	0.130 4	...	0.021 5	0.763 3

实验中我们采用结果对比来验证模型的优劣,对比的模型为:

- 遗传算法得到最优参数的 SVR。
- 原始数据训练的深度 BP 神经网络。

每次实验从原始样本中随机取出 10 个作为预测值,剩余的数据作为训练集分别对遗传算法改进 SVR、深度 BP 神经网络进行训练,然后使用除去预测值的扩增样本训练扩增深度神经网络。

实验总共进行了 7 组预测,表 2 为不同组别不同模型下的 RMSE 值。

表 2 随机测试数据在不同模型下的 RMSE

序号	扩增样本	原数据 BP	原数据 SVR
1	0.035 501	0.099 021	0.090 028
2	0.049 720	0.078 024	0.061 222
3	0.048 416	0.050 016	0.071 152
4	0.051 008	0.078 302	0.065 928
5	0.043 849	0.064 655	0.046 351
6	0.046 670	0.075 369	0.067 002
7	0.050 092	0.059 514	0.071 529

从表 2 可以看出,原始数据训练的神经网络的拟合效果除了第 3 组和第 7 组优于 SVR 之外,其他 5 组拟合效果均不如 SVR。这说明大多数情况下小样本的拟合 SVR 是普遍优于神经网络的,也一定程度上说明传统的武器效能评估模型的不稳定性,使得在效能评估的时候难以抉择合适的模型。但是,扩增样本训练的深度神经网络的 RMSE 值均小于原数据训练得到的神经网络和 SVR,说明该模型的拟合效果要优于 SVR 和小样本训练得到的神经网络。另外,从第 1 组、第 2 组和第 6 组数据结果可以看出,本文提出的模型要优于两个对比的传统模型,这种差异在图 4 中表现得更加直观。图 4 为 7 组随机测试数据在不同模型下的 RMSE 柱状图。




图 4 7 组随机测试数据在不同模型下的 RMSE

为了更好地展示各模型的综合优劣性,对 7 组 RMSE 求均值,如图 5 所示。

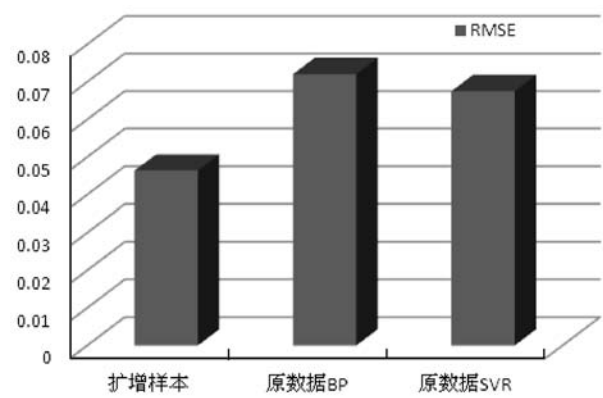


图 5 7 组随机测试数据在不同模型下的 RMSE 均值

扩增样本训练的模型平均 RMSE 为 0.046 5,原数据使用 BP 神经网络训练的模型平均 RMSE 为 0.072 1,原数据使用 SVR 训练的模型平均 RMSE 为 0.067 6,较原数据神经网络训练结果小 0.005 左右,可见在武器系统的小样本数据的效能评估方面,SVR 要优于深度 BP 神经网络,但优势不是非常明显。通过本文模型训练得到的平均 RMSE 最小,比其他两种模型分别小 0.025 6 和 0.021 1,差值明显。由此可得,从综合效果来看,扩增样本训练得到的深度网络模型要远优于传统的两种对比模型。

选取其中一组的结果进行展示,图 6 为第 7 组对应的实际值和预测结果。




图 6 模型预测结果和真实值对比

从图 6 可以看出,原数据训练的深度 BP 神经网络和 SVR 拟合的效果各有优劣,但是扩增样本训练的深度网络模型的拟合曲线明显更契合原始数据点。从单组拟合效果来看,本文的模型优于传统的两种模型。

从上述所有结果中可以看出,无论从单组的误差还是均误差亦或是拟合效果,扩增样本训练的深度神经网络都明显优于其他两个算法。这是由于扩增样本通过扩充深度神经网络中的训练数据,使得其模型预测效果更佳。

在实验过程中发现,对于某些异常值(如第 4 组实验结果中的标记点),三个模型预测效果均比较差,如图 7 所示。




图7 模型预测结果和真实值对比(含异常值)

图7中的标记点及其图6中的第2个点,对应三种模型预测的结果都比较差,因此可以假设原专家给分或测试可能有误,或其不是来自于统一标准。以往在专家或测试给出评测之后,无法得知此次评估是否与先前的经验有较大的差别,而现在可将该系统的评估结果输入到判别网络对其进行打分,验证其与先前的评估是否存在较大差异,进而决定专家是否需要再一次的进行讨论评估或测试。

## 4 结 语

本文探索性地将生成对抗网络与深度BP神经网络结合建立模型,并将其应用于武器系统评估。利用对抗网络可以产生更加清晰且接近真实的样本,用以解决武器系统评估或测试中样本量较少、无法满足训练深度网络要求的问题。同时,判别网络还对评估或者测试的结果是否存在问题为专家提供了一定参考。此外,模型中扩展样本训练的深度网络,还为以往需要大量专家工作或者专业人员测试的评估问题提供了一种简洁高效的解决方法。通过对比实验,验证了本文模型的可行性及其优越性,探索性地将深度学习方法融入到军工方面。

虽然GAN模型崩溃和训练不收敛的问题已经基本被解决,但是对GAN模型还存在一定的影响,同时GAN模型不适合处理离散形式的数据,如文本数据等。这一系列的问题都使得GAN模型的应用受到了限制,因此其应用领域还需要不断扩大与发展。本文的实验模型虽然一定程度上解决了武器系统效能评估中少样本的问题,但是对于几十个甚至更少样本量的武器系统的评估仍然无法达到令人满意的效果,这一方向将是未来研究的重点。

## 参 考 文 献

- [1] 周江,周浩,田斌. 武器系统效能评估方法浅析[J]. 科技资讯,2014,12(16):213-213.
- [2] 高彬,郭庆丰. BP神经网络在电子战效能评估中的应用[J]. 电光与控制,2007,14(1):69-71.
- [3] 谷加臣,丁桂强,刘朝阳,等. 基于遗传算法神经网络的电子对抗效能评估方法研究[J]. 通信对抗,2017,36(2):45-49.
- [4] 曹星平. 支持向量机在武器系统效能评估中的应用[J]. 系统仿真学报,2008,20(24):6599-6602.
- [5] 陈文奇,吉国力. 基于模糊综合评判的电子战效能评估[J]. 厦门大学学报(自然科学版),2006,45(S1):327-330.
- [6] 郭业波,曾博韬,郭贤生. 武器装备系统效能评估方法研究[J]. 宇航总体技术,2017,1(3):65-74.
- [7] Goodfellow I J, Pougetabadi J, Mirza M, et al. Generative adversarial nets[C]//International Conference on Neural Information Processing Systems, 2014:2672-2680.
- [8] Ratliff L J, Burden S A, Sastry S, et al. On the characterization of local nash equilibria in continuous games[J]. IEEE Transactions on Automatic Control, 2016, 61(8):2301-2307.
- [9] 高强,姜思昊. 基于GAN等效模型的小样本库扩增研究[J]. 电测与仪表,2019,56(6):76-81.
- [10] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2014, 18(7):1527-1554.
- [11] Schmidhuber J. Deep learning in neural networks: an overview[J]. Neural Netw, 2015, 61:85-117.
- [12] 刘靖旭. 支持向量回归的模型选择及应用研究[D]. 长沙:国防科学技术大学,2006.
- [13] 刘琳,陈云翔. 综合电子战系统作战效能评估[J]. 火力与指挥控制,2008,33(3):97-99.
- [14] 冉小辉,朱卫纲,邢强. 电子对抗干扰效果评估技术现状[J]. 兵器装备工程学报,2018,39(8):123-127.
- [15] 王博阳,甘荣兵,张京瑞. 电子对抗作战效能评估技术综述[J]. 电子信息对抗技术,2017,32(4):54-60.
- [6] Dutertre B, De Moura L. A fast linear-arithmetic solver for DPLL(T)[C]//Proceedings of the 18th international conference on Computer Aided Verification. Springer-Verlag, 2006:81-94.
- [7] Procaccia A D. Cake cutting algorithms[M]//Handbook of Computational Social Choice, 2016:311-329.
- [8] Bouveret S, Cechlárová K, Elkind E, et al. Fair division of a graph[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence(IJCAI-17), 2017:135-141.
- [9] Thomson W. Fair allocation rules[M]//Handbook of Social Choice and Welfare, 2011:393-506.
- [10] 金继伟,马菲菲,张健. SMT求解技术简述[J]. 计算机科学与探索, 2015, 9(7):769-780.

(上接第252页)