

基于神经网络的小样本轴承球可靠度评估*

Reliability Assessment of Small Sample Bearing Balls Based on Artificial Neural Network

张中益 沈雪瑾 (上海大学机电工程与自动化学院, 上海 200072)

摘要:为建立轴承球磨损量数学模型并结合模型对样本进行可靠度评估,设计了BP神经网络,对磨损量曲线进行拟合。分析表明,拟合曲线能够很好地表达磨损量的变化趋势。通过提取神经网络的权值、阈值参数,建立了磨损量数学模型,并结合模型和蒙特卡洛法对小样本数据进行了处理,进而基于性能退化量分布评估了轴承球的可靠度。结果表明提出的方法针对基于单一性能退化的小样本可靠度评估问题提供了有效的解决途径。

关键词:轴承球,磨损量,BP神经网络,性能退化,小样本,可靠度

Abstract:A back propagation artificial neural network is designed to fit the curve of bearing balls' wear volumes in this paper. The analysis indicated that the fitting curve could express the trend of wear volumes' changing well. The model of wear volumes can be built through extracting weights and threshold from back propagation neural network, the data got from the model is processed by Monte Carlo methods. At last, the reliability of bearing balls was evaluated by the method which was based on the distribution of performance degradation.

Keywords:bearing ball, wear volumes, back propagation artificial neural network, performance degradation, small samples, reliability

轴承球摩擦磨损试验的研究对滚动轴承寿命预测有着重要的意义。在机械工程领域,大量关于零部件磨损量研究都以神经网络为基础展开,易怀军等^[1]基于隔灰色理论和BP神经网络对火炮身管磨损量进行了预测;DM D'Addona^[2]使用人工神经网络和DNA算法估计刀具磨损量。在产品可靠性试验中,人们总希望能通过较少的样本量得到准确的寿命评估结果,蒋喜^[3]等基于伪寿命分布对小子样电主轴进行了数据扩充,分析了其可靠性;Qin^[4]等基于性能退化分布,扩充滚动轴承性能退化数据,求取可靠度曲线;秦萃晨^[5]结合Bootstrap和Bayes等方法对小样本轴承进行了可靠性评估。

本文针对小样本轴承球可靠度评估问题,设计了单输入单输出BP神经网络用以拟合磨损量曲线,通过提取网络权值、阈值参数拟得磨损量的数学表达式,结合蒙特卡洛方法扩充性能退化数据,基于性能数据的退化量分布进行轴承球的可靠度评估。

1 基于神经网络的磨损模型

1.1 神经网络拟合曲线的基本原理

以Matlab运行环境为基础,对磨损量曲线进行拟合,基本步骤如下:

1)时间t序列作为神经网络的输入向量以T表示,随时间变化的磨损量数据a(t)作为输出向量以A表示。隐含层神经元个数N不定,一般参照经验公式^[6]:

$$N = \sqrt{m+n} + a \quad (1)$$

其中m为输入层节点数,n为输出层节点数,a为1~10的常数,输入层和输出层神经元个数都为1。其中隐含层神经元的N阶权值向量为 W_1 ,N阶阈值为 b_1 ,传递函数 f_1 。输出层N阶权值向量为 W_2 ,N阶阈值为 b_2 ,传递函数为 f_2 。

2)神经网络相关参数设置。主要是隐含层的神经元个数、传递函数、目标误差等参数。

3)等待网络训练结束后提取所有权值和阈值,按照相应的运算法则,获得轴承球磨损量与时间的数学表达式,最终建立磨损量曲线随时间变化的数学模型。 f_1 对应的是S型函数(logsig), f_2 对应的是线性传递函数(purelin)。

$$f_1(x) = \frac{1}{1 + \exp(-x)} \quad (2)$$

$$f_2(x) = x \quad (3)$$

根据网络结构与运算法则,可得磨损量与时间的关系式(4),联合式(2)、式(3)对式(4)进行简化得式(5)。

$$A = f_2(f_1(T * W_1 + b_1) + b_2) \quad (4)$$

$$a(t) = b_2 + \sum_{j=1}^n w_{2j} g \frac{1}{1 + \exp(-(w_{1j}t + b_{1j}))} \quad (5)$$

其中, w_{1j} 是权值向量 W_1 的元素, b_{1j} 是隐含层阈值向量 b_1 的元素。 w_{2j} 是权值向量 W_2 的元素, b_2 是输出层单个神经元的阈值。上述推导只和神经网络的初始设置有关不受试验条件影响,因此该推导过程具有一般性。最终只需提取神经网络训练后的权值和阈值,就能算得统一的数学表达式。

1.2 曲线拟合效果对比分析

以直径为6.35mm轴承钢球为例,该样本所受载荷210N,试验机的滑滚比0.005,取0~2000分钟的试验数据作为BP神经网络的训练样本进行曲线拟合。图1、图2分别对比了BP神经网络拟合曲线与四次多项式和幂函数拟合曲线。四次多项式在1000~2000分钟时段能够较好地拟合实际磨损曲线,但对初始阶段的拟合效果并不理想。幂函数在0~700分钟左右时能够较好地拟合和磨损量曲线,1500~2000分钟时的拟合轨迹与实际轨迹偏差越来越大。BP神经网络拟合效果要优于常规曲线拟合方法。




图1 基于四次多项式与神经网络的磨损量曲线拟合图




图2 基于幂函数与神经网络的磨损量曲线拟合图

1.3 小结

BP神经网络拟合的曲线较常规拟合方法能够更好地表达实际磨损量曲线的变化趋势,而且拟合曲线整体平稳光滑。

在试验过程中测得的磨损量数据总是有限的,而神经网络拟合曲线所构成的数学表达式可计算得到任意时刻点的磨损量,能够作为后续轴承球可靠度评估有效的数据来源,提供更充分的理论依据。因此本文将使用BP神经网络拟合曲线代替试验测得的磨损量数据进行后续分析。

2 小样本轴承球可靠度评估

2.1 基于性能退化量分布的可靠度评估

假设有 n 个样本,在实验过程中,在每个时刻点 $t_j(j=1,2,\dots,m,m$ 为正整数)记录下各个样本的退化量 $y_{ij}(i=1,2,\dots,n,n$ 为样本个数),如式(6)所示。

$$Y = \begin{bmatrix} y_{1,1} & \cdots & y_{1,m-1} & y_{1,m} \\ \vdots & \cdots & \vdots & \vdots \\ y_{n-1,1} & \cdots & y_{n-1,m-1} & y_{n-1,m} \\ y_{n,1} & \cdots & y_{n,m-1} & y_{n,m} \end{bmatrix} \quad (6)$$

根据K-S假设对每个时刻点退化量是否服从正态分布进行检验,并计算出每个时刻点退化量分布参数。如果性能退化量服从正态分布,期望 μ 和标准差 σ 计算如式(7)、(8)所示。

$$\hat{\mu}_j = \frac{1}{n} \sum_{i=1}^n y_{ij} \quad (7)$$

$$\hat{\sigma}_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \hat{\mu}_j)^2} \quad (8)$$

其中 i 表示第几个样本, $i=1,2,\dots,n$; j 表示第几次记录试验值, $j=1,2,\dots,m$ 。计算得到每个时刻退化量的均值 $\hat{\mu}_j$ 和标准差 $\hat{\sigma}_j$ 后,则在时刻 t_j 处样本的可靠度^[7]为:

$$\hat{R}_j = \Phi\left(\frac{l - \hat{\mu}_j}{\hat{\sigma}_j}\right) \quad (9)$$

2.2 轴承球可靠性分析过程

整个可靠性分析过程如下所示:

- 1)使用BP神经网络对 n 个样本的磨损量数据进行曲线拟合,获取各样本磨损量数学模型;
- 2)在各拟合曲线上截取 m 个时刻点的磨损量数据 $\text{data}(t_j, y_j)$,并检验个时刻点磨损量服从分布;
- 3)基于蒙特卡洛模拟扩充各时刻点的磨损量数据,并计算个时刻点的可靠度 \hat{R}_j 。

2.3 实例分析及对比

对直径 6.35mm 的轴承钢球进行同工况的磨损寿命试验,滑滚比 0.95,载荷 265N。当轴承球明显进入剧烈磨损阶段且磨损量达到 1.4mm³ 即判定轴承球失效。试验中投入 3 个样本,全部失效,失效时间依次为 5351min、4622min 和 5547min。

各样本的磨损量的神经网络拟合曲线见图3。




图3 基于神经网络拟合的磨损量曲线

根据上面的流程对轴承球样本进行可靠性分析获得可靠度曲线,同时对比 DDBMC^[4]方法和 Bootstrap-Bayes 方法^[5],得到不同方法的可靠度分析结果,如图4所示。




图4 不同方法的可靠度分析结果

观察图4,三条可靠度曲线从初始时刻到4000分钟这一时段基本重合,且可靠度高,同时对比试验,也没有出现失效样本。可以发现4000分钟开始 Bootstrap-Bayes 方法首先出现可靠度下降现象,但该曲线整体较为平滑稳定。DDBMC 可靠度从4200分钟开始有下降趋势,本文方法的可靠度从4500分钟开始有急剧下降的趋势,再对比实际的三个试验失效数据4622分钟、5351分钟和5547分钟,本文方法对比另外两种方法其可靠度开始下降的时间更接近实际试验第一个样本发生失效的时间,本文方法所得结果较另外两种方法相对更准确,符合工程实际。

总体来说三个方法的可靠度分析结果相似,与本文方法相比较另外两种方法结果更为保守,本文方法计算的可靠度更高,其描述的可信度变化趋势更符合实际试验结果。

3 结束语

1)基于BP神经网络建立的数学模型与基于四次多项式和基于幂函数建立的模型比较更贴合实际磨损量曲线,精度更高,拟合效果更好。

2)DDBMC 和 Bootstrap-Bayes 方法计算得到的可靠度相对更为保守,本文计算得到的可靠度更高,样本的预期寿命更长,且对比实际的试验结果,本文方法所得到的可靠度曲线更加符合工程实际,准确性相对更高。

3)针对小样本基于单一性能的可靠度评估问题,本文给出了一种有效的解决方法,可为制定提高轴承球可靠性的相关决策提供依据。

参考文献

- [1]易怀军,刘宁,张相炎,等.基于优化的非等间隔灰色理论和BP神经网络的身管磨损量预测[J].兵工学报,2016,37(12):2220-2225
- [2]D'Addona D, Ullah A, Matarazzo D. Tool-wear prediction and pattern-recognition using artificial neural network and DNA-

0.6931。图3中, GAN做了5次实验, 在迭代次数为40000次左右时, 因为损失过大, 终止了实验。图4中, GCAN的生成器个数从1个逐渐增加到101个, 可以看见, 生成器损失逐渐趋近于取得最优解时的损失。其中, 当G的个数取101个时, 损失曲线收敛于最优解损失曲线。




图3 GAN生成的数字, 40000次迭代时崩成1




图4 GCAN设置10个G, 生成的数字

3.2 ReSigm和Sigmoid对比

在ReSigm的实验中, 为了与GAN做对比, 设置G的个数均为1。ReSigm的超参数设为: $\alpha=0.0000001$ 。如图5~图7。

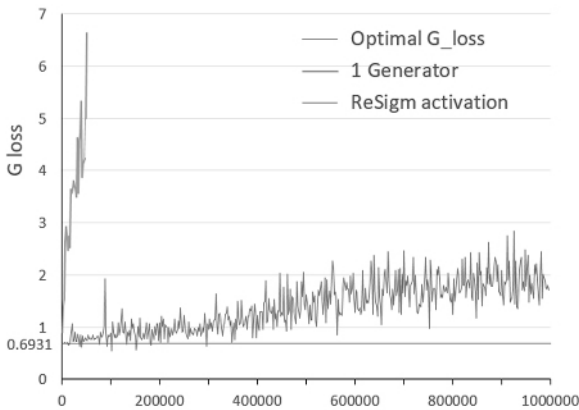


图5 GAN用Sigmoid和ReSigm的对比




图6 Sigmoid非饱和区间




图7 ReSigm非饱和区间

ReSigm扩大了非线性饱和区间, 使得梯度信息能有效回传, 增大了容量。在MNIST数据集上的实验, 当迭代到1000000次时, 损失函数基本能维持在比较接近最优解的位置。生成的数字图像如图8所示, 可发现在300000次迭代时生成的数字依然清晰、多样。




图8 激活函数采用ReSigm时, GAN生成的数字

4 结束语

今后还将研究GCAN无限个生成器时的架构设计、在自然图像和人脸图像上的生成性能、ReSigm的超参数的设计, 以及多个G和多个D之间合作或不平等竞争关系等。除此之外, 还要致力于找出G的个数增多与网络收敛之间的函数关系。

参考文献

- [1] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets [C]//International Conference on Neural Information Processing Systems, 2014
- [2] Arjovsky M, Bottou L, Léon. Towards Principled Methods for Training Generative Adversarial Networks [C]//Conference paper on ICLR 2017, 2017
- [3] Arjovsky M, Chintala S, Bottou L. Wasserstein GAN [C]//Conference paper on ICLR 2017, 2017
- [4] Lucic M, Kurach K, Michalski M, et al. Are GANs Created Equal A Large-Scale Study [J]. arXiv:1711.10337, 2017
- [5] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization [C]//Conference Paper on ICLR, 2015
- [6] Heusel M, Ramsauer H, Unterthiner T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium [C]//International Conference on Neural Information Processing Systems, 2017
- [7] Radford A, Metz L, Chintala S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks [C]//Conference Paper on ICLR, 2016

[收稿日期: 2019.1.14]

(上接第67页)

- based computing [J]. Journal of Intelligent Manufacturing, 2017, 28(6): 1-17
- [3] 蒋喜, 刘宏昭, 刘丽兰, 等. 基于伪寿命分布的电主轴极小子样可靠性研究 [J]. 振动与冲击, 2013, 32(19): 80-85
- [4] Qin Luo-sheng, Shen Xue-jin, Chen Xiao-yang, et al. Reliability assessment of bearings based on performance degradation values under small samples [J]. Strojniski Vestnik - Journal of Mechanical Engineering, 2017, 41(2): 205-217

- [5] 秦萃晨, 陈晓阳, 沈雪瑾. 小样本下基于竞争失效的轴承可靠性评估 [J]. 振动与冲击, 2017, 36(23): 248-254
- [6] 高大启. 有教师的线性基本函数前向三层神经网络研究 [J]. 计算机学报, 1998(1): 80-86
- [7] 邓爱民, 陈循, 张春华, 等. 基于性能退化数据的可靠性评估 [J]. 宇航学报, 2006, 72(3): 546-552

[收稿日期: 2019.1.7]